IUM zadanie 07 wariant 02

- Korneliusz Litman 310804
- Marcin Zasuwa 311022

Etap 1

Kontekst:

> W ramach projektu wcielamy się w rolę analityka pracującego dla portalu „Pozytywka” – serwisu muzycznego, który swoim użytkownikom pozwala na odtwarzanie ulubionych utworów online. Praca na tym stanowisku nie jest łatwa –zadanie dostajemy w formie enigmatycznego opisu i to do nas należy doprecyzowanie szczegółów tak, aby dało się je zrealizować. To oczywiście wymaga zrozumienia problemu, przeanalizowania danych, czasami negocjacji z szefostwem. Same modele musimy skonstruować tak, aby gotowe były do wdrożenia produkcyjnego – pamiętając, że w przyszłości będą pojawiać się kolejne ich wersje, z którymi będziemy eksperymentować.

Zadanie

> “Gdybyśmy tylko wiedzieli, kiedy użytkownik będzie chciał przesłuchać bieżący utwór w całości, a kiedy go przewinie – moglibyśmy lepiej zorganizować nasz cache”

Definicja problemu biznesowego

Kontekst

Serwis muzyczny Pozytywka umożliwia użytkownikom odtwarzanie utworów. Firma zbiera informacje m.in. dotyczczące artystów, utworów czy sesji użytkowników. W celu zwiększenia wydajności i poprawy doświadczeń użytkowników serwis Pozytywka chce ulepszych organizację cache poprzez przewidywanie, kiedy utwory będą odtwarzane w całości, a które będą przewijane

Zadanie biznesowe

Opracowanie i wdrożenie modelu predykcyjnego, który na podstawie dostępnych danych i historii użytkowników, będzie w stanie przewidywać prawdopodobieństwo, że użytkownik odtworzy utwór w całości lub go przewinie.

Biznesowe kryteria sukcesu

Wariant 1

- Zwiększenie satysfakcji użytkowników poprzez zmniejszenie czasu oczekiwania na załadowanie piosenek
- Priorytetyzowanie cachowania piosenek, które mają większe prawdopodobieństwo, że zostaną odtworzone w całości

Wariant 2

- Zwiększenie satysfakcji użytkowników poprzez rekomendowanie im piosenek, na które istnieje mniejsza szansa, że zostaną pominięte
- Zmniejszenie procentowe pomijanych utworów co najmniej o 5%

Analityczne kryteria sukcesu

Naiwny model, który zawsze przewiduje, że utwór zostanie odtworzony w całości, osiągnie wynik zbliżony do `65.88%` dokładności.
Wynika to z tego, że w dostarczonym zbiorze danych `65.88%` utworów zostało odtworzonych w całości.
Celem jest stworzenie predykcyjnego modelu, który przewiduje z dokładnością wyższą niż `65.88%` prawdopodobieństwo czy utwór zostanie odtworzony w całości, czy zostanie pominięty.

Definicja zadania / zadań modelowania i wszystkich założeń

Zadania modelowania: Model predykcyjny, który na podstawie dostarczonych danych będzie w stanie przewidzieć, czy utwór zostanie odtworzony w całości, czy zostanie przewinięty.

Analiza danych

Przegląd struktury dostarczonych danych

Dostaliśmy dane składające się z 5 plików `jsonl`

- `artists.jsonl` zawiera informacje o artystach
- `sessions.jsonl` zawiera informacje o sesjach użytkowników
- `tracks.jsonl` zawiera informacje o utworach
- `track_storage.jsonl` zawiera informacje o tym na jakich klasach pamięci są przechowywane utwory
- `users.jsonl` zawiera informacje o użytkownikach portalu

Wstępne założenia

Aby sprawdzić czy utwór został przesłuchany w całości, czy został pominięty, należy przeanalizować plik `sessions.jsonl`

- podstawowym kryterium analizy jest sprawdzenie czy wystąpił `event_type` *SKIP* pomiędzy `event_type` *PLAY*
- na skipowanie utworów mogą wpływać wartości charakterystyczne dla danych utworów: niektóre utwory mogą być skipowane częściej niż inne
- skipowane utwory mogą też zależeć od preferencji użytkownika np. użytkownik lubi rock, przez co istnieje szansa, że takie utwory będą skipowane przez niego rzadziej

Analiza za pomocą programów

Do analizy danych wykorzystaliśmy Pythonową bibliotekę `pandas` służącą do analizy danych.

Pierwsza wersja

Pierwsza wersja otrzymanych danych zawierała istotne błędy w dużym stopniu utrudniające dalszą analizę.
Większość tych błędów polegała na nullowych i nieprawidłowych wartościach:

Raport z analizy

- Artyści (`artists.jsonl`):
  - Wartość -1 dla `id` występuje 494 razy,
  - Brak wartości (`null`) w polu `genres`: 544 wystąpień,
  - Zduplikowane nazwy artystów: 14.
- Sesje (`sessions.jsonl`):
  - Brak wartości (`null`) w polu `event_type`: 167 wystąpień,
  - Brak wartości (`null`) w polu `track_id`: 163 wystąpień,
  - Brak wartości (`null`) w polu `user_id`: 195 wystąpień.
- Utwory (`tracks.jsonl`):
  - Brak wartości (`null`) w polu `id`: 1117 wystąpień,
  - Brak wartości (`null`) w polu `name`: 1083 wystąpień,
  - Brak wartości (`null`) w polu `artist_id`: 1078 wystąpień,
  - Brak wartości (`null`) w polu `popularity`: 1044 wystąpień.
- Użytkownicy (`users.jsonl`):
  - Występuje pole `id` dla jednego rekordu, które nie istnieje dla innych rekordów (wartość pola: -1),
  - Brak wartości (`null`) w polu `favourite_genres`: 5,
  - Brak wartości (`null`) w polu `premium_user`: 1.
- W pliku z danymi o przechowywaniu utworów (`track_storage.jsonl`) nie znaleźliśmy problemów.

Druga wersja

tracks.jsonl

W danych dalej występują błędy - dla kilku artystów powtarzają się nazwy utworów dla nich samych (występują duplikaty par nazwa utworu - artysta).
Nie jest to sytuacja całkowicie niespotykana, jednak na tyle rzadka, że została uznana za błąd w danych.

Lista duplikatów wraz z ilością wystąpień:

```
Duplicate entries for artist id: 1uNFoZAHBGtllmzznpCI3s and track name: Hold On -
4 occurrences
Duplicate entries for artist id: 6M2wZ9GZgrQXHCFfjv46we and track name: Blow Your
Mind (Mwah) - 4 occurrences
Duplicate entries for artist id: 4tpUmLEVLCGFr93o8hFFIB and track name: Atomic -
3 occurrences
Duplicate entries for artist id: 5tOrTQaBRD5yPHqbEwsRn7 and track name: 99 Year
Blues - 3 occurrences
...
```

Pełna lista znajduje się w pliku `analysis/analysis_duplicate_track_names.txt`

track_storage.jsonl

W porównaniu do pierwszej wersji wszystkie wpisy `track_storage.jsonl` z `track_id` mają odpowiadający id z `tracks.json`

sessions.jsonl

- Dane zawierające eventy w sesjach wydają się być poprawne: dla każdego wpisu podany jest odpowiedni `track_id`, który ma odzwierciedlenie w pliku tracks.json (oprócz 3853 eventów typu ADVERTISTMENT lub BUY_PREMIUM, które go nie wymagają)
- Liczba event_type SKIP wynosi 4090, co sugeruje, że odpowiednia wielkość danych wydaje się być zachowana
- Kolejna analiza pokazała, że każdy event_type SKIP jest dla danej sesji poprzedzony (niekoniecznie bezpośrednio) event_type typu PLAY. Czyli dane w tym zakresie wydają się być poprawne. Ta cecha będzie miała kluczowe znaczenie dla naszego zadania (pozwala określić)
- Kolejna analiza pokazała statystyki po jakim czasie utwory są najczęściej pomijane.

```
When track was skipped:
mean: 132.50 seconds
median: 125.88 seconds
min: 0.09 seconds
max: 1057.39 seconds
std: 90.49 seconds
```

- Procentowa liczba pominiętych utworów: `34.12%`

Przygotowaliśmy histogram dla przedstawionych danych:

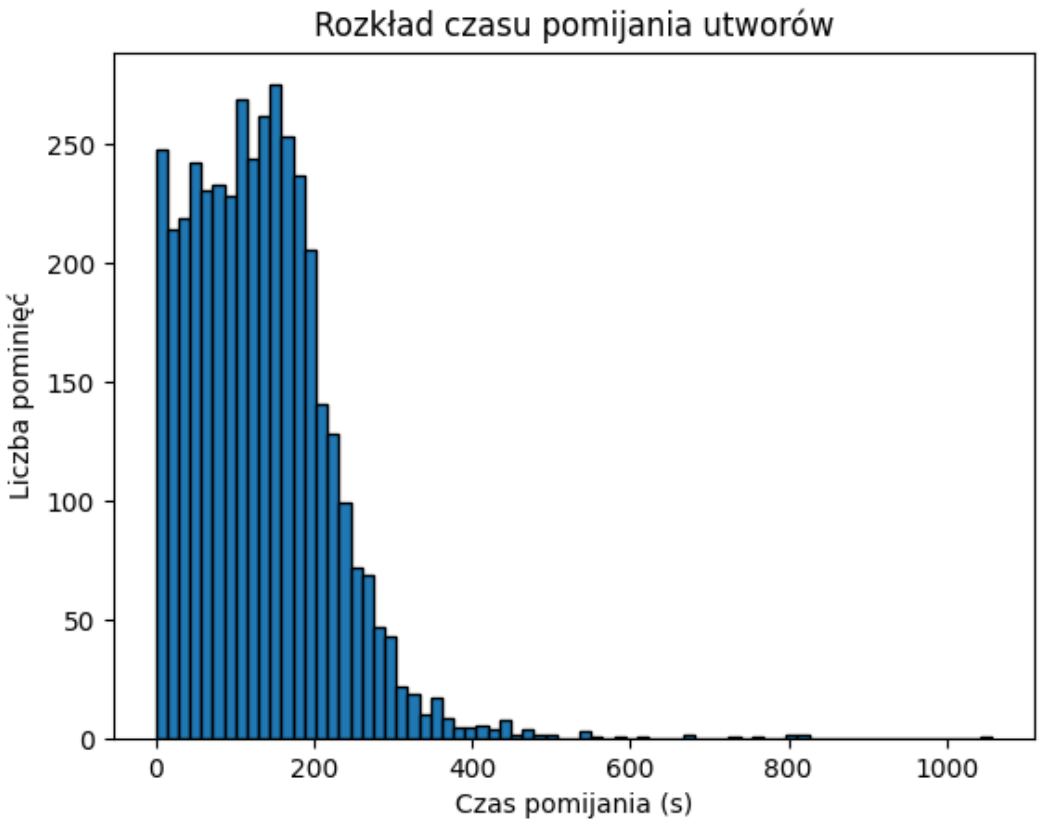

tracks.jsonl

Następnie przygotowaliśmy statystyki długości trwania utworów:

```
count    21608
mean       228.06 seconds
std        112.11 seconds
min          4.00 seconds
25%        176.74 seconds
50%        216.51 seconds
75%        262.65 seconds
max       4120.26 seconds
```

Zaznaczyliśmy je na wykresie (zaznaczając dodatkowo 1 i 99 percentyl)

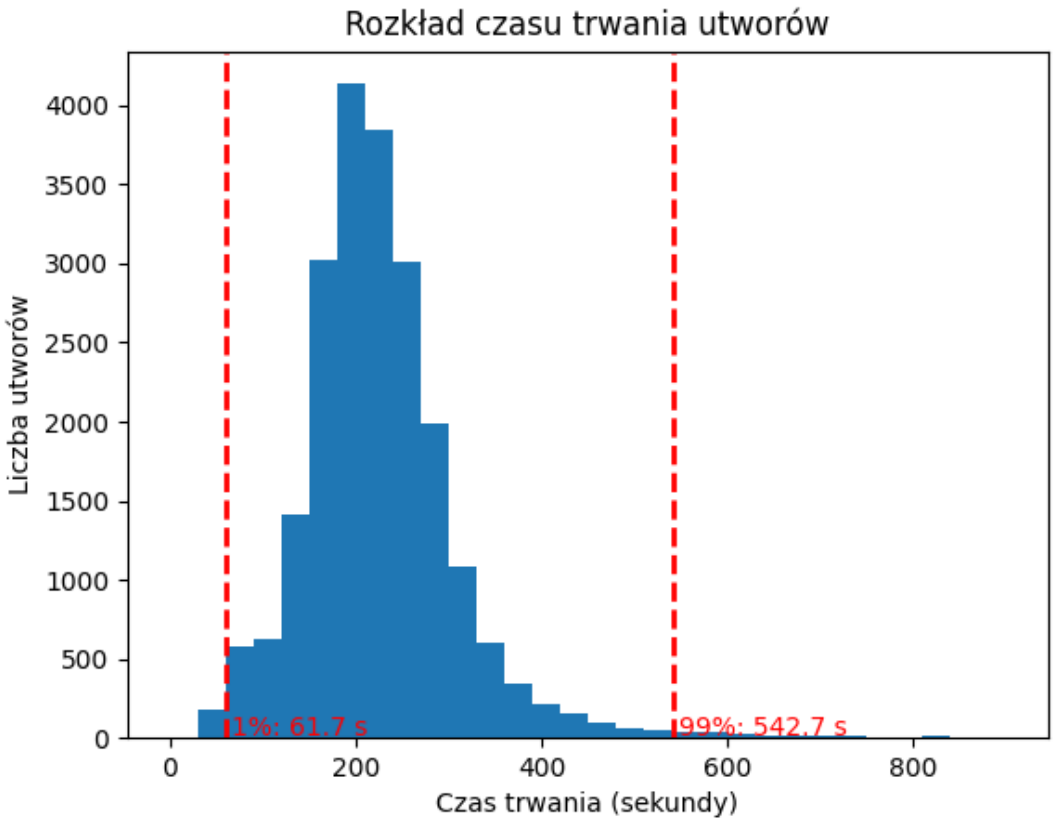

Przygotowaliśmy kolejne histogramy dla kolejnych danych:

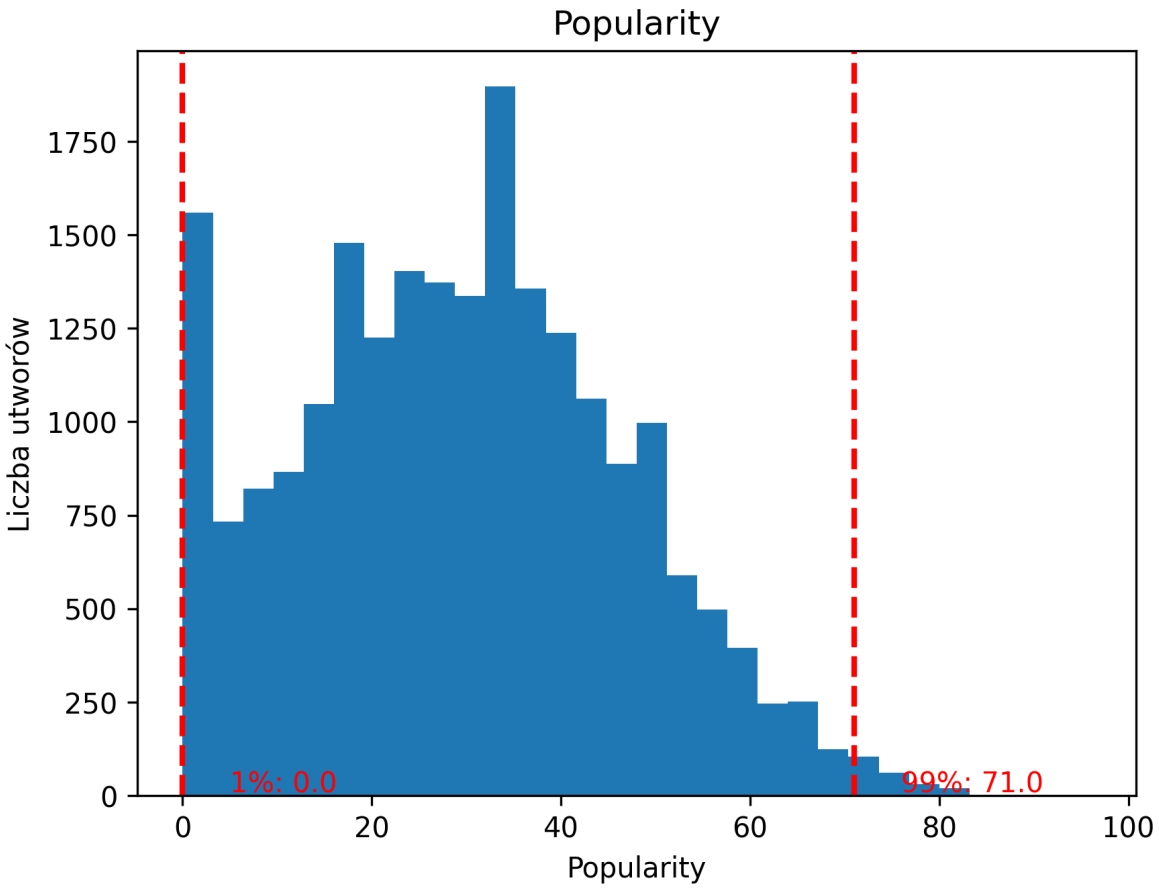

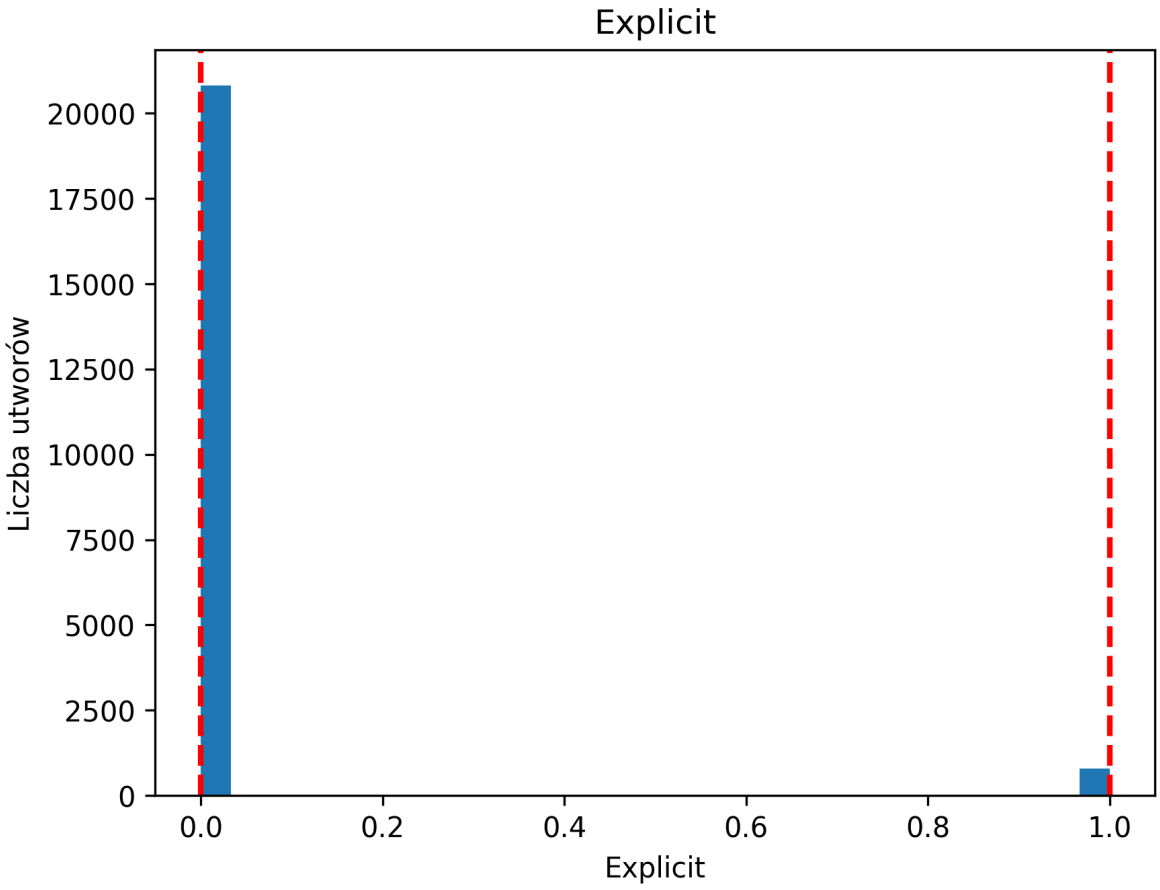

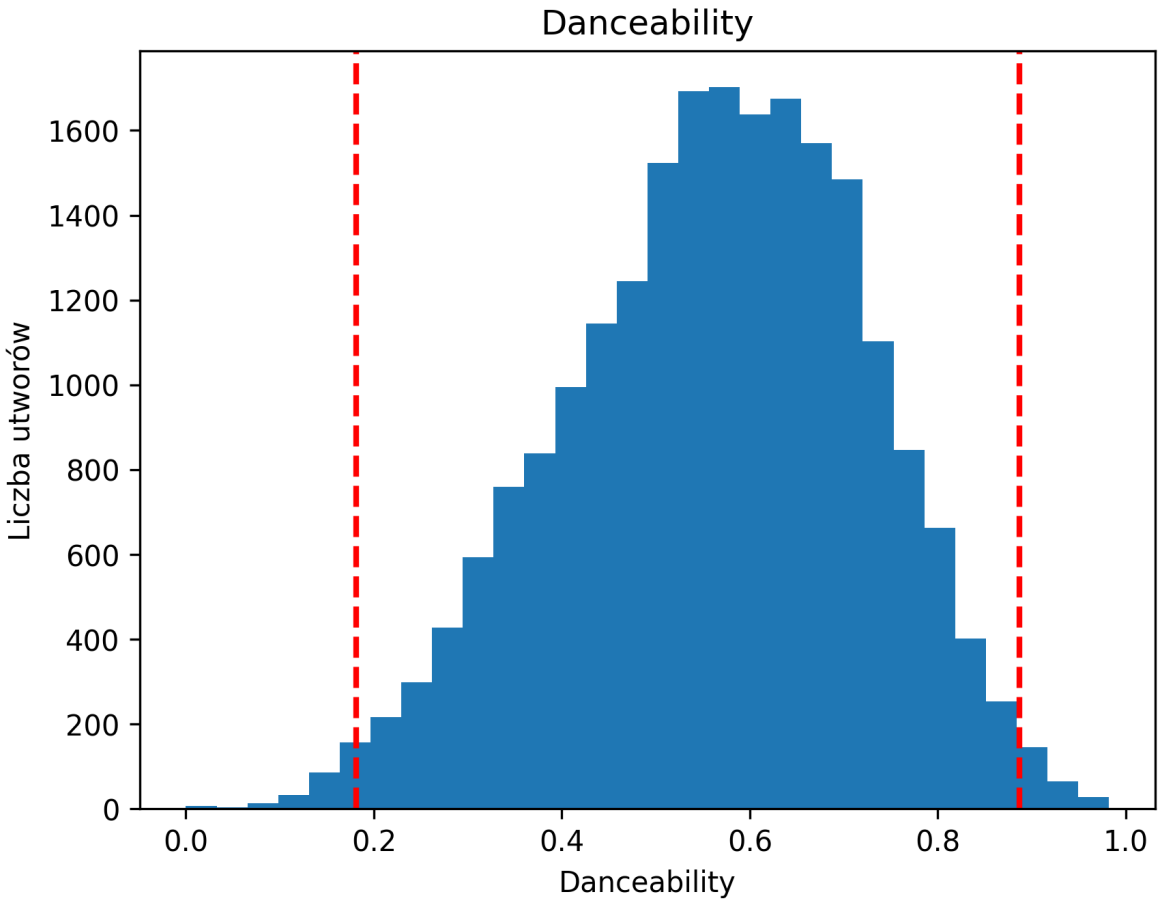
Danceability
Liczba utworów
0
200
400
600
800
1000
1200
1400
1600
0.0
0.2
0.4
0.6
0.8
1.0
Danceability

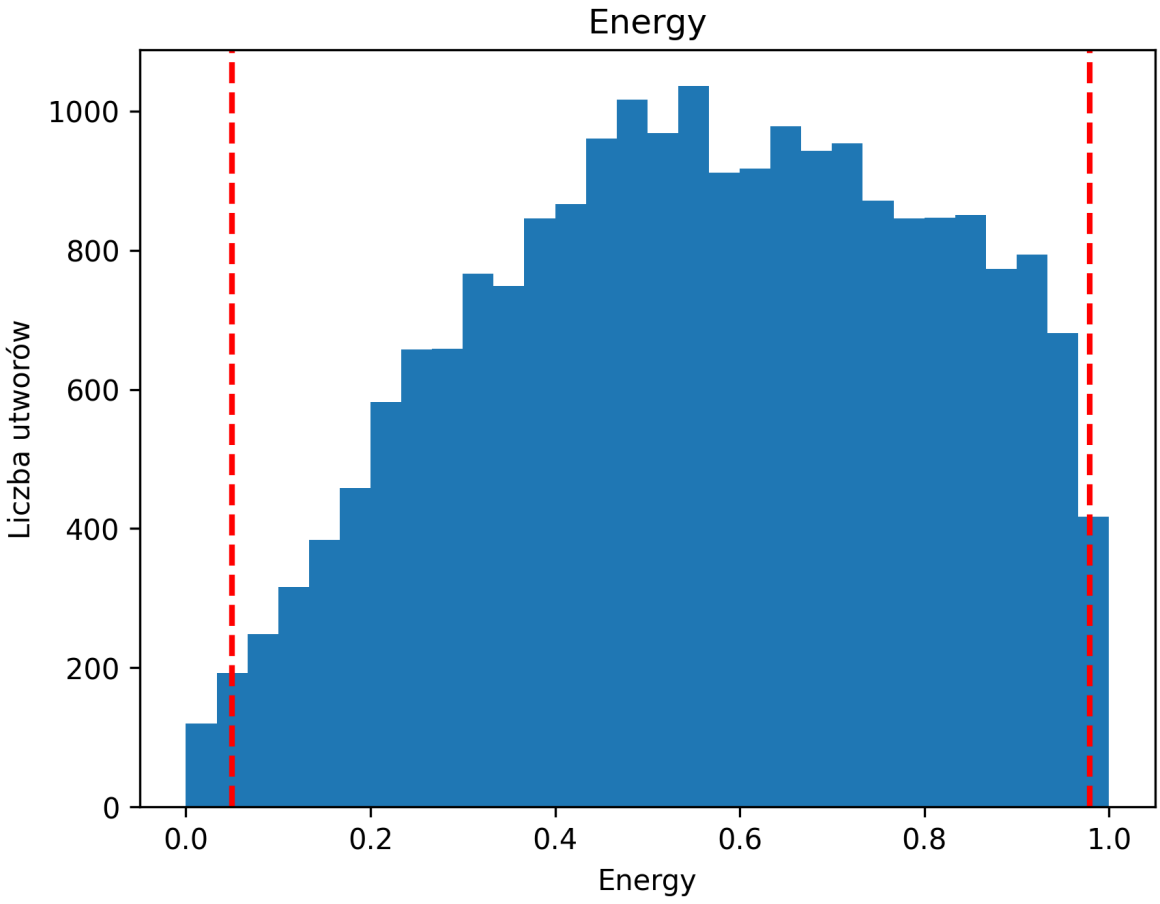
Energy
Liczba utworów
0
200
400
600
800
1000
0.0
0.2
0.4
0.6
0.8
1.0
Energy

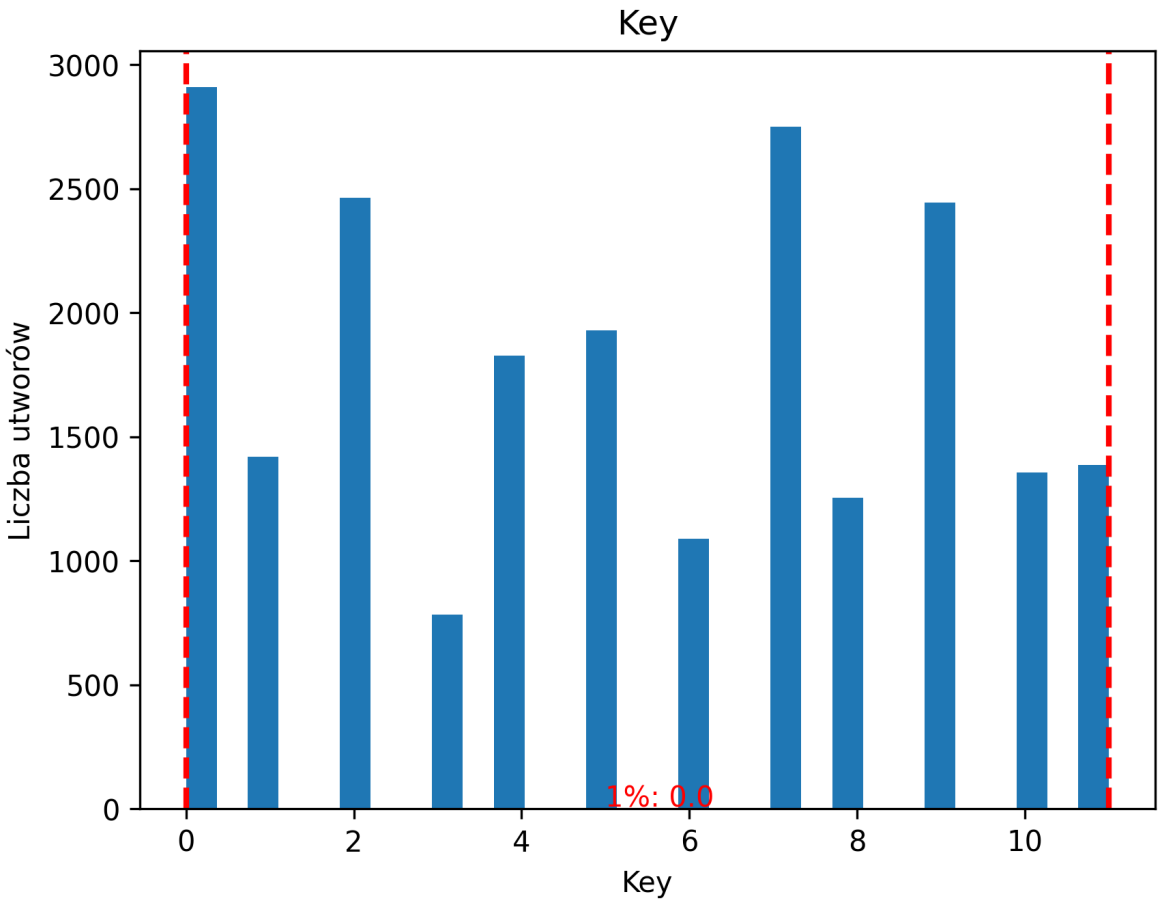
Key
Liczba utworów
Key
1%: 0.0
0
500
1000
1500
2000
2500
3000
0
2
4
6
8
10

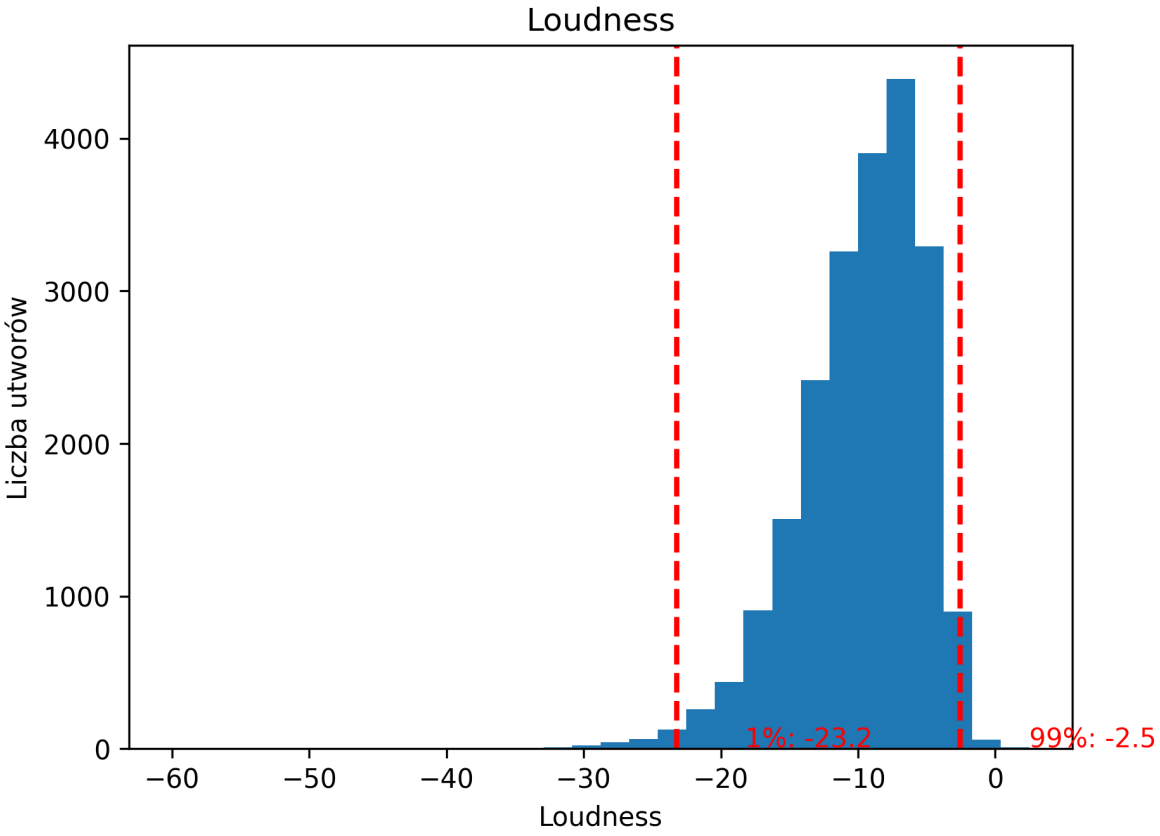
Loudness
Liczba utworów
Loudness
1%: -23.2
99%: -2.5
0
1000
2000
3000
4000
−60
−50
−40
−30
−20
−10
0

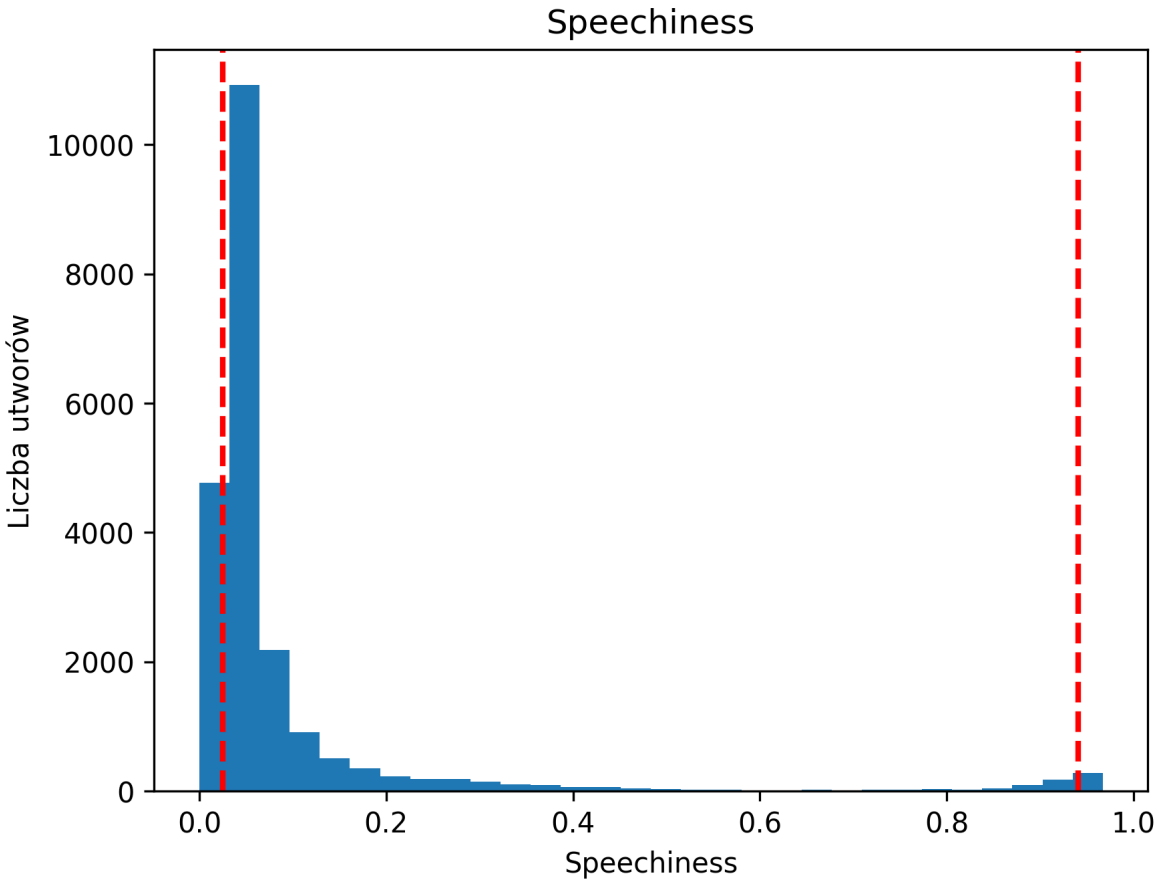
Speechiness
Liczba utworów
10000
8000
6000
4000
2000
0
0.0
0.2
0.4
0.6
0.8
1.0
Speechiness

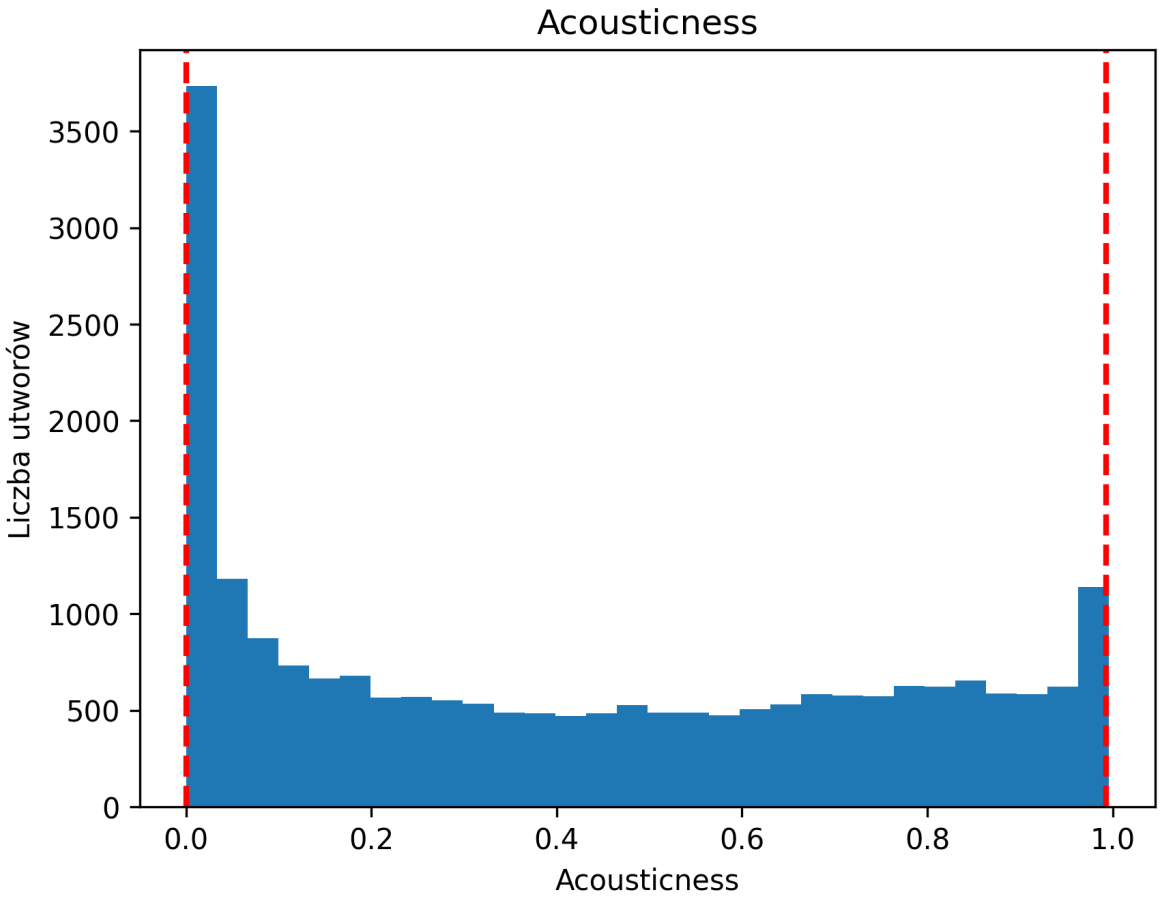
Acousticness
Liczba utworów
3500
3000
2500
2000
1500
1000
500
0
0.0
0.2
0.4
0.6
0.8
1.0
Acousticness

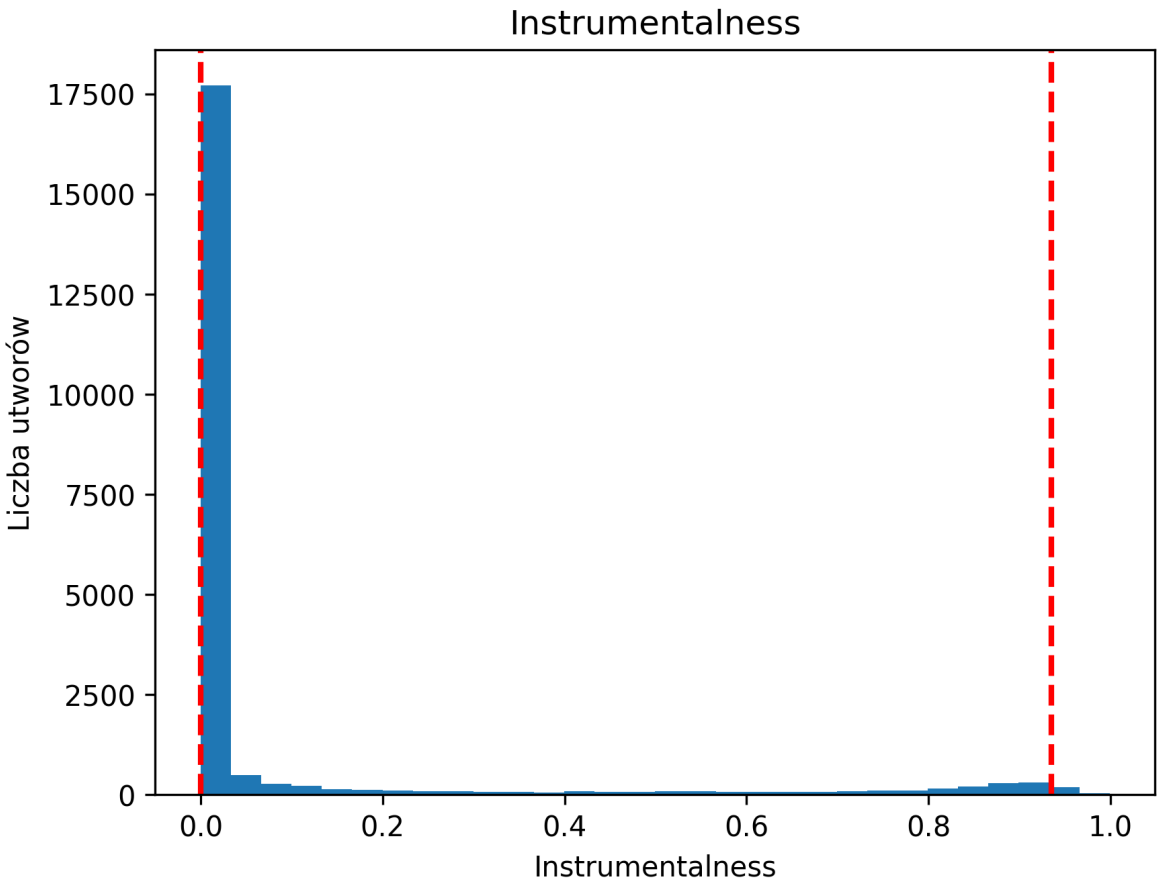
Instrumentalness
17500
15000
12500
10000
7500
5000
2500
0
Liczba utworów
0.0
0.2
0.4
0.6
0.8
1.0
Instrumentalness

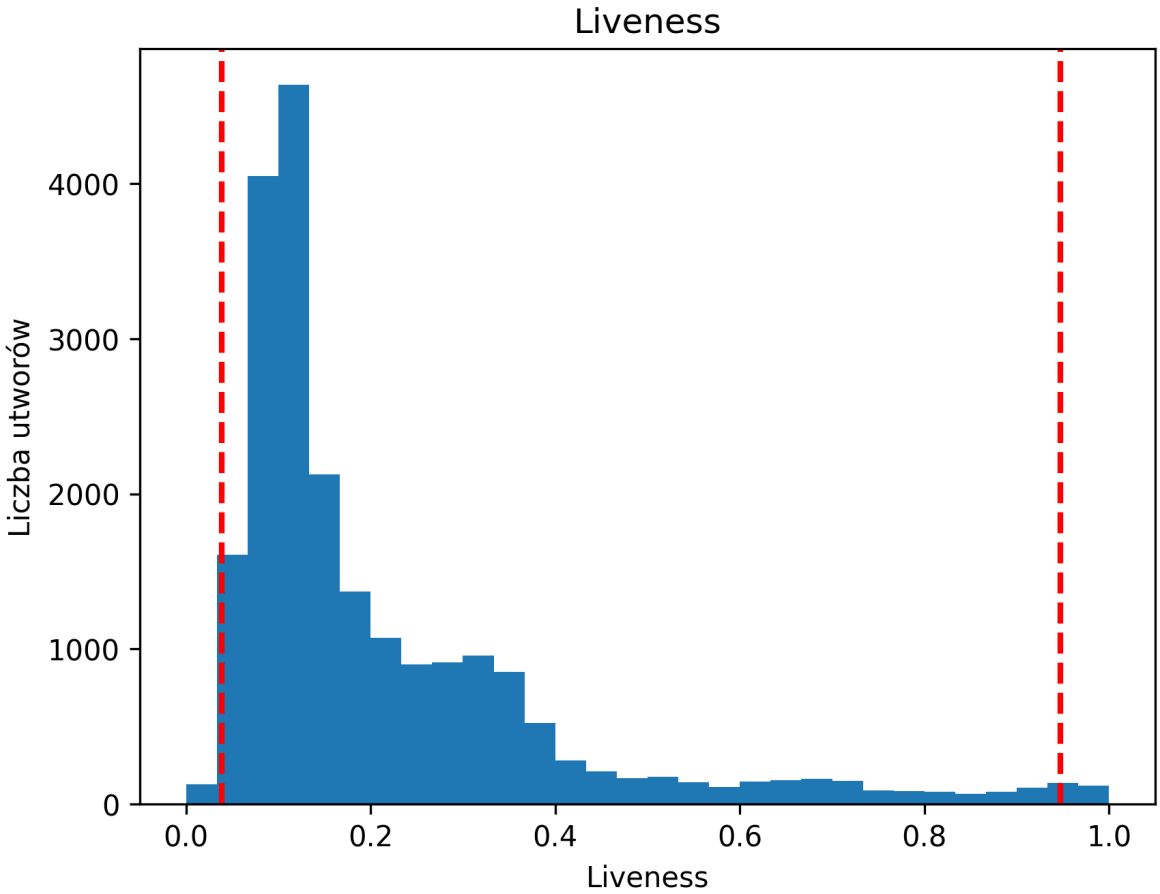
Liveness
4000
3000
2000
1000
0
Liczba utworów
0.0
0.2
0.4
0.6
0.8
1.0
Liveness

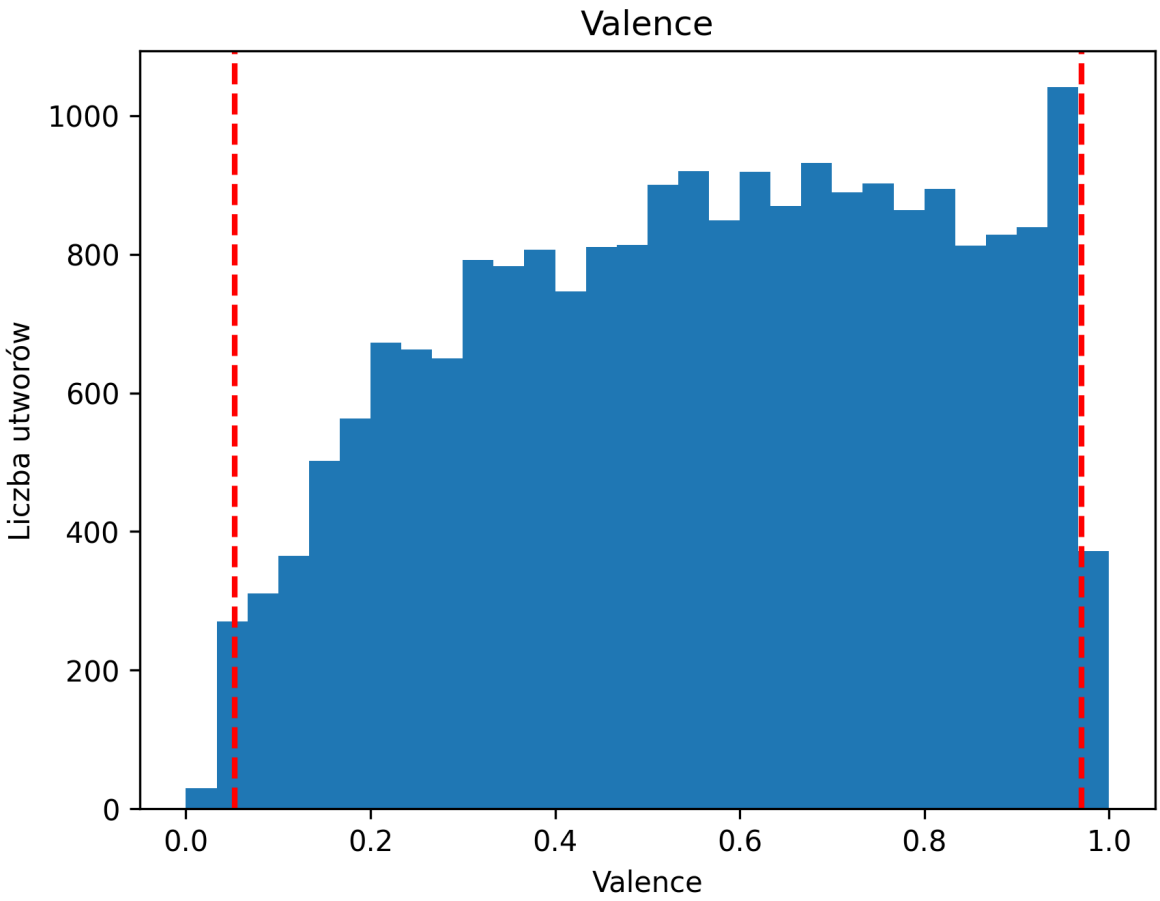
Valence
Liczba utworów
0
200
400
600
800
1000
0.0
0.2
0.4
0.6
0.8
1.0
Valence

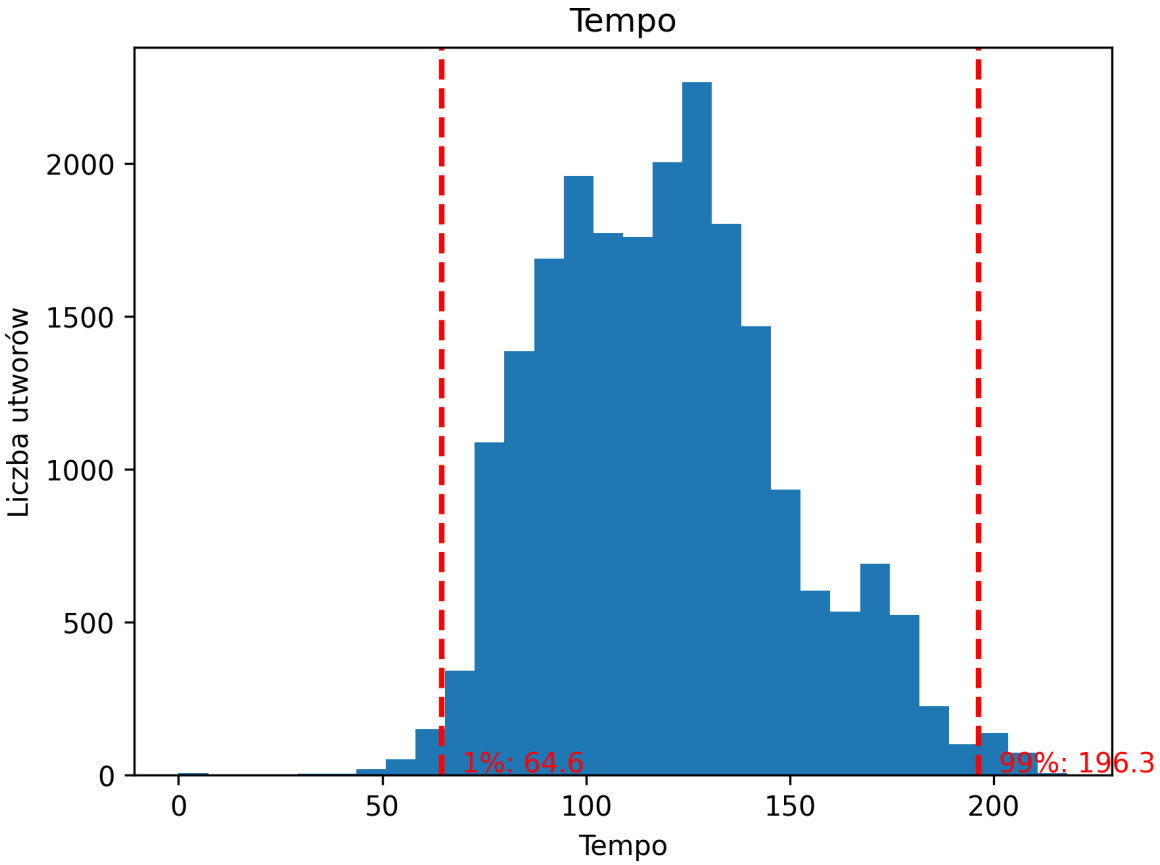
Tempo
Liczba utworów
0
500
1000
1500
2000
0
50
100
150
200
Tempo
1%: 64.6
99%: 196.3

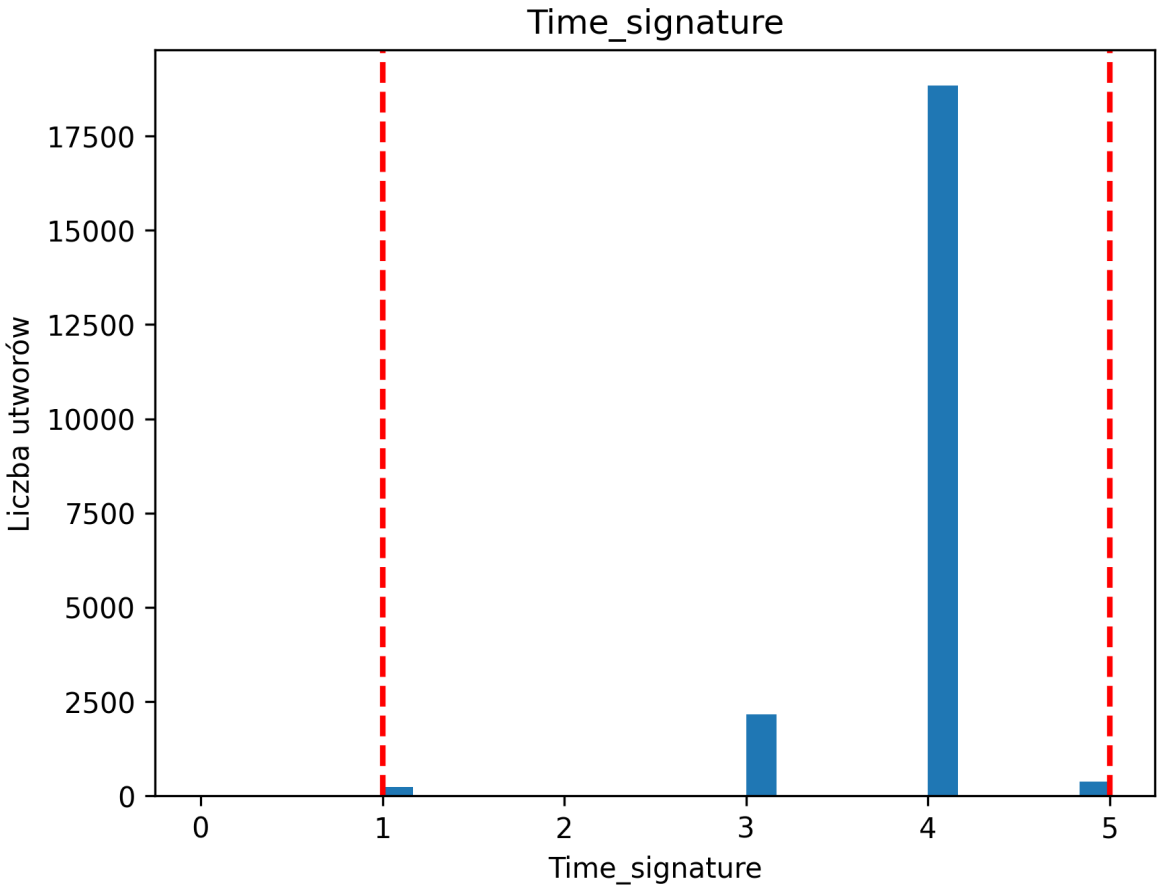

Na podstawie przedstawionych histogramów możemy wnioskować, że nie wszystkie atrybuty niosą istotne informacje dla zadania.

Transformacja

Aby uprościć strukturę danych, dane z pliku `sessions.jsonl` zostały poddane transformacji. Wyliczono następujące wartości:

- `advertisementBefore` (określa czy bezpośrednio przed utworem została odtworzona reklama)
- `skipped` (określa czy utwór został pominięty)
- `likedWhilePlaying` (czy podczas odtwarzania utworu został on polubiony)

Współczynniki korelacji dla atrubutów ciągłych

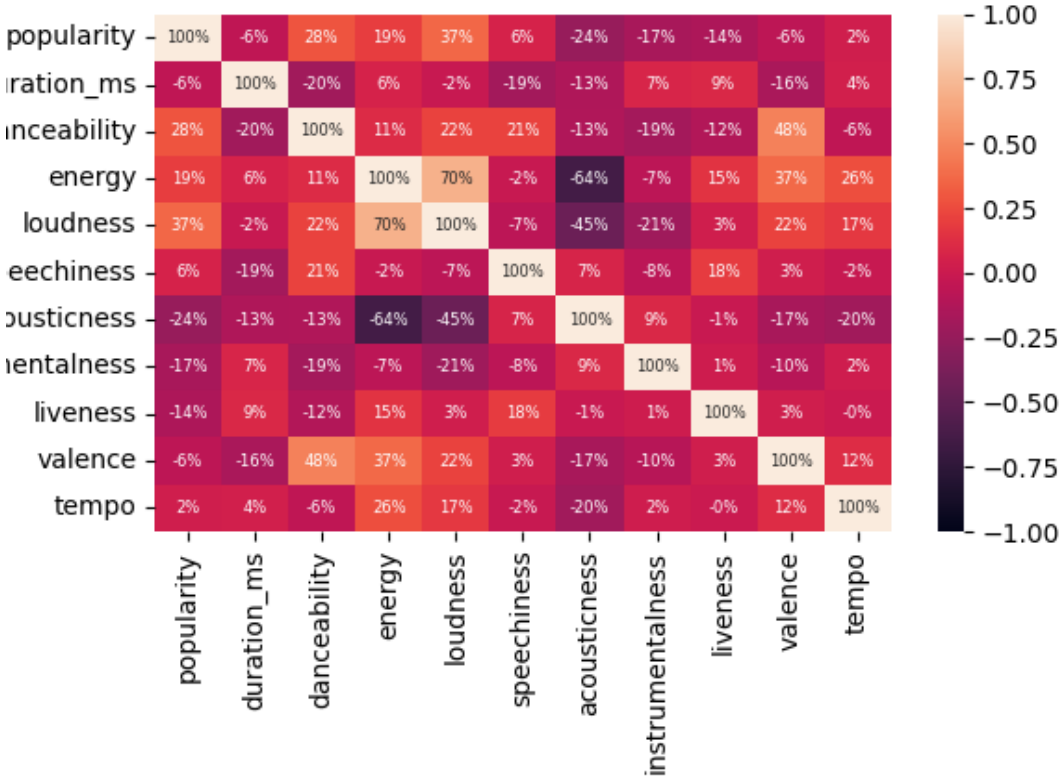

Współczynniki informacji wzajemnej

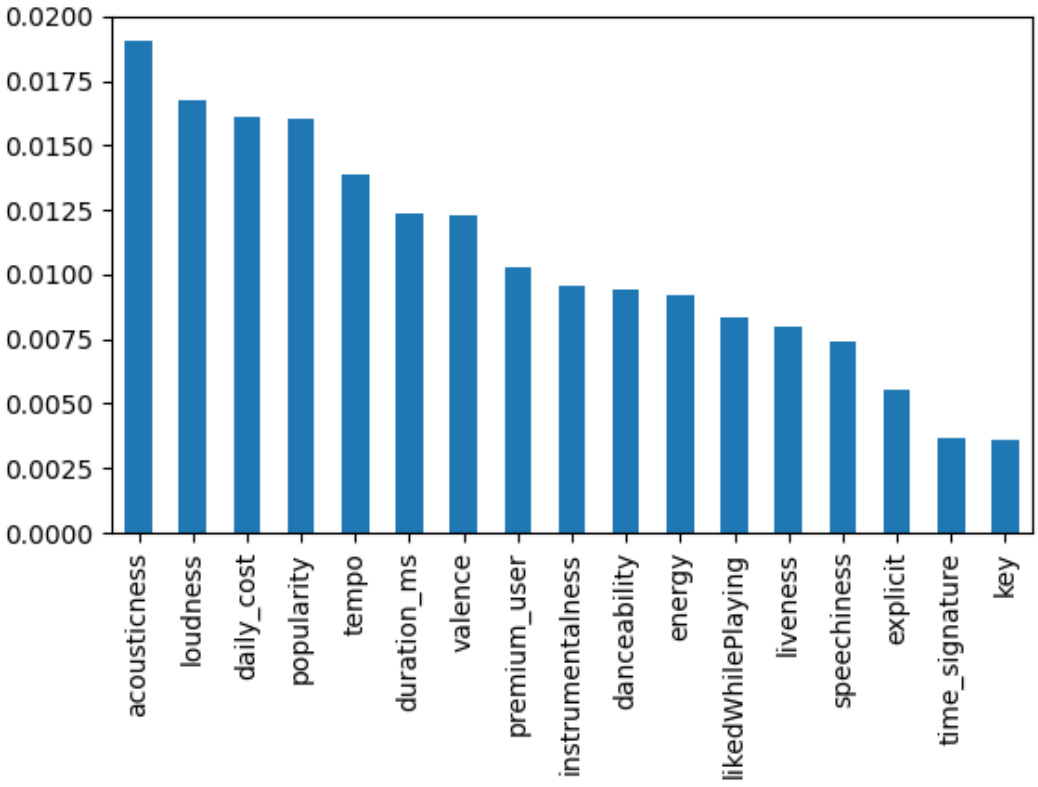

Po obliczeniu współczynnika informacji wzajemnej między dostarczonymi danymi, a zmienną celu, wynika, że dostarczone dane nie niosą zbyt dużo informacji o zmiennej celu.
Nawet największa wartość współczynnika informacji wzajemnej jest poniżej 2%.

Wstępnie zdefiniowane danych wejściowych

Przy wstępnej próbie użyto MLPClassifier okazało się, że na poprawę modelu w sposób dość znaczący wpływa personalizacja utworów pod użytkownika, na podstawie jego ulubionych gatunków muzycznych
(`71.23%` vs `59.80%`).
Istotne jest zatem uwzględnienie `favourite_genres`, `genres` w modelu.
Większość innych atrybutów nie niesie wiele informacji i nie wpływa w znaczący sposób na poprawę modelu (potwierdza to wyznaczone wcześniej współczynniki informacji wzajemnych)

Etap 2

Modele

- Modele zostały przygotowane w języku Python z wykorzystaniem PyTorch.
- Modele są oparte o perceptrony wielowarstwowe (MLP)
- Do trenowania modeli wykorzystano rdzenie CUDA w GPU Nvidia.

Proces budowy modelów

Przygotowanie danych

Za pomocą skryptu `transformation/transform_sessions.py` dane zostały przeformatowane do uproszczonej postaci. Zawiera ona etykietę mówiącą o tym czy utwór został pominięty, czy nie

Etapy przygotowania danych do trenowania

- Wczytanie danych z plików wejściowych
- Łączenie danych w jeden duży zestaw danych
- Wektoryzacja tekstu na liczby za pomocą mechanizmu TF-IDF
- Redukcja wymiarowości za pomocą PCA (Principal Component Analysis)
- Klasteryzacja danych za pomocą algorytmu KMeans
- Kodowanie danych One-hot
- Podział danych na zbiór treningowy i testowy
- Normalizacja danych za pomocą StandardScaler
- Przepróbkowanie danych za pomocą SMOTE (Synthetic Minority Oversampling Technique) aby zrównoważyć klasę mniejszościową w zestawie danych

Opis budowy modeli

Budowa modelu Simple

- Model złożony z 3 warstw
    - Pierwsza warstwa: 50 neuronów, Funkcja aktywacji: ReLU
    - Druga warstwa: 30 neuronów, Funkcja aktywacji: ReLU
    - Trzecia warstwa: 2 neurony
- CrossEntropyLoss i optimizer Adam
- 1000 epok

Budowa modelu Advanced

- Model złożony z 4 warstw
  - Pierwsza warstwa: 100 neuronów, Funkcja aktywacji: ReLU
  - Dropout z prawdopodobieństwem 0.5
  - Druga warstwa: 50 neuronów, Funkcja aktywacji: ReLU
  - Dropout z prawdopodobieństwem 0.5
  - Trzecia warstwa: 30 neuronów, Funkcja aktywacji: ReLU
  - Czwarta warstwa: 2 neurony
- CrossEntropyLoss i optimizer Adam
- scheduler ReduceLROnPlateau
- 1000 epok

Uruchomienie trenowania

Wszystkie kroki trenowania można wykonać używając jednego skryptu:

```
DATA_VERSION=<data_version> CUDA_USE_GPU=<cuda_use_gpu> ./prepare_models.sh
```

gdzie:

- `data_version` - wersja danych wejściowych (domyślnie `v2`)
- `cuda_use_gpu` - czy używać GPU (`0` lub `1` - domyślnie `1`)

Modele

Simple

Przewiduje czy utwór zostanie pominięty czy nie tylko na podstawie favourite_genres użytkownika i genres utworu

Advanced

Przewiduje czy utwór zostanie pomięty czy nie na podstawie favourite_genres użytkownika, genres utworu oraz dodatkowych informacji o utworze.

Porównanie modeli

Dane v2:

- Simple: `70.74%`
- Advanced: `73.27%`

Dane v3:

- Simple: `63.49%`
- Advanced: `62.23%`

Inne próby

RandomForest i GradientBoosting

Próby z wykorzystaniem RandomForest i GradientBoosting nie przyniosły zadowalających rezultatów. Ponieważ wykorzystywane trenowanie na CPU ich trenowanie trwało dużo dłużej

Mikroserwis

Mikroserwis został zaimplementowany w języku Python z wykorzystaniem FastAPI. Jest on udostępniony jako obraz Dockerowy.

Uruchomienie mikroserwisu

Aby uruchomić mikroserwis, należy skopiować plik `.env.example` do `.env` i uzupełnić go odpowiednimi wartościami.

```
cp .env.example .env
```

Następnie należy zbudować obraz Dockerowy i uruchomić go:

```
docker-compose up -d --build
```

Endpointy

Lista modeli

`GET /api/models`

Zwraca dostępne modele (`simple` i `advanced`)

Predykcja z wykorzystaniem konkretnej wersji modelu

`POST /api/predict/{model_name}`, gdzie model_name `simple` lub `advanced`

Przykładowe request body:

```
{
    "track_id": "0qGcYAUhkokluTCAuLUSdY",
    "favourite_genres": [
        "argentine rock"
    ]
}
```

Przykładowy response:

```
{
    "skipped": false
}
```

Predykcja z wykorzystaniem losowej wersji modelu do przeprowadzenia testów A/B

`POST /api/predict/random`
Informacje o predykcji są zapisane do dokumentowej bazy danych MongoDB.
Dane te mogą posłużyć do późniejszej oceny jakości modeli.

Prezentacja działania mikroserwisu